

# 第2章 確率分布

---

2009/06/05(金)

PRMLゼミ

M1 山田孝太郎

1. 二値変数の確率分布
  - ベータ分布
2. 多値変数の確率分布
  - ディリクレ分布
3. ガウス分布
  - 条件付きガウス分布
  - 周辺ガウス分布
  - ガウス変数に対するベイズの定理
  - ガウス分布の最尤推定
  - 逐次推定(来週)

- 密度推定

- 観測値の集合 $\{X_1, \dots, X_n\}$ が与えられた時に、確率変数 $X$ の従う確率分布を求めること。
- 候補は無数にあるので、多項式曲線フィッティングやモデル選択問題と関係がある。

- パラメトリックな確率分布

- パラメータによって定まる確率分布を求める
  - 頻度主義的アプローチ: 尤度関数などの基準最適化
  - ベイズ主義的アプローチ: 事前分布を導入し、パラメータが得られた時の事後分布を求める。

- ノンパラメトリックな確率分布

- 分布の形状を制限しない。
- データ集合の大きさに形状が依存
- パラメータはあっても分布の複雑さの調整

# 1. 二値変数

- **ベルヌーイ分布**: 二値確率変数  $x \in \{0, 1\}$  が従う分布

例) 歪なコイン投げ

表( $x=1$ )が出る確率  $\mu$  ( $0 \leq \mu \leq 1$ ) のコイン

裏( $x=0$ )が出る確率  $1 - \mu$

なので,  $x$  の値をとる確率は

$$\text{Bern}(x|\mu) = \mu^x (1 - \mu)^{1-x}$$

となる。これがベルヌーイ分布の確率密度関数。

- **二項分布**: 表が出る回数  $m$  の確率分布

$$\text{Bin}(m|N, \mu) = \binom{N}{m} \mu^m (1 - \mu)^{N-m}.$$

ただし,

$$\binom{N}{m} \equiv \frac{N!}{(N-m)!m!}$$

$$\mathbb{E}[m] \equiv \sum_{m=0}^N m \text{Bin}(m|N, \mu) = N\mu$$

$$\text{var}[m] \equiv \sum_{m=0}^N (m - \mathbb{E}[m])^2 \text{Bin}(m|N, \mu) = N\mu(1 - \mu)$$

という  $N$  個から  $m$  個取り出す組み合わせの数

# 1. 二値変数

データ集合  $D = \{x_1, \dots, x_n\}$  が取れたとき、尤度関数は、

$$p(\mathcal{D}|\mu) = \prod_{n=1}^N p(x_n|\mu) = \prod_{n=1}^N \mu^{x_n} (1 - \mu)^{1-x_n}$$

となる。

ここで、頻度主義的に $\mu$ を求める・・・尤度関数最大化！

尤度関数の対数をとって、

$$\ln p(\mathcal{D}|\mu) = \sum_{n=1}^N \ln p(x_n|\mu) = \sum_{n=1}^N \{x_n \ln \mu + (1 - x_n) \ln(1 - \mu)\}.$$

$\mu$ で微分し、微分係数を=0とおいて $\mu$ の最尤推定量を求めると

$$\mu_{\text{ML}} = \frac{1}{N} \sum_{n=1}^N x_n$$

という、サンプル平均が求められる。

# 1.1 ベータ分布

- 頻度主義的では、データ集合が少ない時、過学習の可能性 (ex. 3回投げて3回表が出る)  
⇒ ベイズ主義的アプローチ: パラメータの事前分布  $p(\mu)$  を設定

- どう設定するか？

- 事後分布  $\propto$  事前分布  $\times$  尤度関数

⇒ 事前分布と事後分布は同じ関数形 (共役性)

- ベータ分布

$\mu$  と  $(1-\mu)$  のべき乗の形


$$\mathbb{E}[\mu] = \frac{a}{a+b}$$

$$\text{Beta}(\mu|a, b) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} \mu^{a-1} (1-\mu)^{b-1}$$

$$\text{var}[\mu] = \frac{ab}{(a+b)^2(a+b+1)}$$

- パラメータ  $a, b$  は  $\mu$  の分布を決めるので、超パラメータと呼ばれる。

いろいろな  $a, b$  のときのベータ分布の形



# 1. 1 ベータ分布

- 事後分布 $\propto$ 事前分布 $\times$ 尤度関数(二項分布)として $\mu$ に関する項だけにし, 正規化係数をつけると

$$p(\mu|m, l, a, b) = \frac{\Gamma(m+a+l+b)}{\Gamma(m+a)\Gamma(l+b)} \mu^{m+a-1} (1-\mu)^{l+b-1}$$

となり、 $l=N-m$ (裏の出た回数)である。

- つまり, あるデータ集合が得られた時,  $a$ と $b$ をそれぞれ $m, l$ だけ増やせば, 事前分布から事後分布が求められる。

- このとき $a, b$ は**有効観測数**として解釈できる。

- そして, 得られた事後分布は次の試行の事前分布となりうる。

⇒**逐次学習**のアプローチ

例) あるデータ集合が得られたときの次の試行で表が出る確率

$$p(x=1|\mathcal{D}) = \int_0^1 p(x=1|\mu)p(\mu|\mathcal{D}) d\mu = \int_0^1 \mu p(\mu|\mathcal{D}) d\mu = \mathbb{E}[\mu|\mathcal{D}]$$

結局,

$$p(x=1|\mathcal{D}) = \frac{m+a}{m+a+l+b}$$

## 2. 多値変数

- 異なるK個の可能な状態を取りうる確率変数についての記述

1対K法:

変数は要素の一つ $x_k$ が1で残りは0と記述されるようなベクトルになる。たとえば $K=6$ で $x_3=1$ のときは

$$\mathbf{x} = (0, 0, 1, 0, 0, 0)^T$$

$X$ の分布は,  $X_k=1$ となる確率を $\mu_k$ とおくと,

$$p(\mathbf{x}|\boldsymbol{\mu}) = \prod_{k=1}^K \mu_k^{x_k}$$

となる。これはベルヌーイ分布の一般化である。



## 2. 多値変数

- あるデータ集合 $x_1, \dots, x_N$ がとれたとき, 尤度関数は,

$$p(\mathcal{D}|\mu) = \prod_{n=1}^N \prod_{k=1}^K \mu_k^{x_{nk}} = \prod_{k=1}^K \mu_k^{(\sum_n x_{nk})} = \prod_{k=1}^K \mu_k^{m_k}$$

となる。この式からN個のデータ点は, K個の

$$m_k = \sum_n x_{nk}.$$

の値によってきまる。これは, 各 $x_k$ が出た回数であり, **十分統計量**と呼ばれる。

この尤度関数を条件

$$\sum_{k=1}^K \mu_k = 1$$

のもとで最大化(ラグランジュ乗数法)し, 最尤推定解を求めると,

$$\mu_k^{\text{ML}} = \frac{m_k}{N}$$

となる。これは全体の中で $x_k$ が出た割合。

## 2. 多項分布

• パラメータ $\mu$ (各 $x_k$ が出る確率のベクトル)と観測値数 $N$ が与えられたとき,  $m_1, \dots, m_K$ の同時確率分布は

$$\text{Mult}(m_1, m_2, \dots, m_K | \mu, N) = \binom{N}{m_1 m_2 \dots m_K} \prod_{k=1}^K \mu_k^{m_k}$$

という**多項分布**の形になる。

$$\binom{N}{m_1 m_2 \dots m_K} = \frac{N!}{m_1! m_2! \dots m_K!}$$

は,  $N$ 個のものを $m_1, \dots, m_K$ 個ずつの $K$ 個のグループに分割する場合の数である。

したがって, 次の制約条件が付く。

$$\sum_{k=1}^K m_k = N.$$

## 2. 2. 1 ディリクレ分布


- 多項分布もベイズ主義的に考える。  
事前分布⇒多項分布と共役なもの

$$p(\mu|\alpha) \propto \prod_{k=1}^K \mu_k^{\alpha_k-1}$$

ただし,  $0 \leq \mu_k \leq 1, \sum_k \mu_k = 1$

条件より, この分布はK-1次元  
の**単体**上に制限される。




例) K=3のとき



- この共役分布を正規化すると, 次の**ディリクレ分布**を得る

$$\text{Dir}(\mu|\alpha) = \frac{\Gamma(\alpha_0)}{\Gamma(\alpha_1) \cdots \Gamma(\alpha_K)} \prod_{k=1}^K \mu_k^{\alpha_k-1} \quad \text{ただし} \quad \alpha_0 = \sum_{k=1}^K \alpha_k$$

例) K=3のとき  
(縦軸を密度, 横軸は単体上の座標)  
左から  
 $\{\alpha_k\}=0.1, \{\alpha_k\}=1, \{\alpha_k\}=10$



## 2. 2. 1 ディリクレ分布

- 事後分布  $\propto$  事前分布  $\times$  尤度関数とすると。

$$p(\mu|\mathcal{D}, \alpha) \propto p(\mathcal{D}|\mu)p(\mu|\alpha) \propto \prod_{k=1}^K \mu_k^{\alpha_k + m_k - 1}$$

という、事後分布もディリクレ分布の形になる。  
結局、

$$\begin{aligned} p(\mu|\mathcal{D}, \alpha) &= \text{Dir}(\mu|\alpha + \mathbf{m}) \\ &= \frac{\Gamma(\alpha_0 + N)}{\Gamma(\alpha_1 + m_1) \cdots \Gamma(\alpha_K + m_K)} \prod_{k=1}^K \mu_k^{\alpha_k + m_k - 1} \end{aligned}$$

となり、 $\alpha_k$ は $x_k = 1$ となる有効観測数と解釈できる。

## 2.3 ガウス分布

### •1変数の場合

$$\mathcal{N}(x|\mu, \sigma^2) = \frac{1}{(2\pi\sigma^2)^{1/2}} \exp \left\{ -\frac{1}{2\sigma^2} (x - \mu)^2 \right\} \quad \mu \text{は平均}, \sigma \text{は分散}$$

### •多変数の場合




$$\mathcal{N}(\mathbf{x}|\mu, \Sigma) = \frac{1}{(2\pi)^{D/2}} \frac{1}{|\Sigma|^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \mu)^T \Sigma^{-1} (\mathbf{x} - \mu) \right\} \quad (2.43)$$

$\mu$ はD次元の平均ベクトル,  $\Sigma$ はD×D共分散行列,  $|\Sigma|$ は $\Sigma$ の行列式

### •中心極限定理

どんな分布に従う確率変数の和も, 多くの和を取ると, ガウス分布に従うようになる。

例) 一様分布に従うN個の確率変数の平均



## 2.3 ガウス分布の線形変換

• ガウス分布は

$$\Delta^2 = (\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) \quad (2.44)$$

という二次形式で $\mathbf{x}$ に依存する。この $\Delta$ をマハラノビス距離という。

ここで、共分散行列 $\boldsymbol{\Sigma}$ は実対称行列なので、 $i=1, \dots, D$ について固有方程式

$$\boldsymbol{\Sigma} \mathbf{u}_i = \lambda_i \mathbf{u}_i.$$

がかける。実対称行列は対角化できて、

対角成分が $\lambda_i$ のベクトル  $\rightarrow \boldsymbol{\Sigma} = \sum_{i=1}^D \lambda_i \mathbf{u}_i \mathbf{u}_i^T \quad \boldsymbol{\Sigma}^{-1} = \sum_{i=1}^D \frac{1}{\lambda_i} \mathbf{u}_i \mathbf{u}_i^T$

となる。(2.44)に戻すと

$$\Delta^2 = \sum_{i=1}^D \frac{y_i^2}{\lambda_i} \quad (2.50) \quad \text{ここで} \quad y_i = \mathbf{u}_i^T (\mathbf{x} - \boldsymbol{\mu}).$$

となり、 $\mathbf{y} = (y_1, \dots, y_D)^T$  にまとめると、

$$\mathbf{y} = \mathbf{U}(\mathbf{x} - \boldsymbol{\mu}) \quad (2.52)$$

となる。 $\mathbf{U}$ は $\mathbf{u}_i^T$ を $i$ 行に持つ直交行列。

## 2.3 ガウス分布の線形変換

- 共分散行列の行列式 $|\Sigma|$ も固有値の積でかけるので


$$|\Sigma|^{1/2} = \prod_{j=1}^D \lambda_j^{1/2}$$

となり, (2.50)と合わせて(2.43)は

$$p(\mathbf{y}) = p(\mathbf{x})|\mathbf{J}| = \prod_{j=1}^D \frac{1}{(2\pi\lambda_j)^{1/2}} \exp\left\{-\frac{y_j^2}{2\lambda_j}\right\} \quad (2.56)$$

と正規化できる。


例) 二次元空間上のガウス分布  
赤線内が密度一定の楕円体の面  
( $\mu_1, \mu_2$ )方向に新たに楕円の軸が定義される



## 2.3.1 条件付きガウス分布

- 2つの変数集合の同時分布がガウス分布に従うとき
  - 一方の変数集合が与えられたとき, もう一方の条件付き分布もガウス分布に従う(赤)
  - どちらの変数集合の周辺分布もガウス分布に従う(青)C

例) 二次元空間上のガウス分布  
条件付き分布:  $x_b=0.7$ の軸で切った切り口  
周辺分布:  $x_a$ 軸から見た分布の正射影





## 2.3.1 条件付きガウス分布

•  $X$ を二つの互いに素な部分集合 $X_a$ と $X_b$ に分割する。平均と共分散行列も以下のように与えられる。

$$\mathbf{x} = \begin{pmatrix} \mathbf{x}_a \\ \mathbf{x}_b \end{pmatrix} \quad (2.65) \quad \boldsymbol{\mu} = \begin{pmatrix} \boldsymbol{\mu}_a \\ \boldsymbol{\mu}_b \end{pmatrix} \quad (2.66) \quad \boldsymbol{\Sigma} = \begin{pmatrix} \boldsymbol{\Sigma}_{aa} & \boldsymbol{\Sigma}_{ab} \\ \boldsymbol{\Sigma}_{ba} & \boldsymbol{\Sigma}_{bb} \end{pmatrix} \quad (2.67)$$

ただし,  $\boldsymbol{\Sigma}_{ba} = \boldsymbol{\Sigma}_{ab}^T$  である。

• 共分散行列の逆行列(対称行列になる)を考える。これを**精度行列**という。

$$\boldsymbol{\Lambda} = \begin{pmatrix} \boldsymbol{\Lambda}_{aa} & \boldsymbol{\Lambda}_{ab} \\ \boldsymbol{\Lambda}_{ba} & \boldsymbol{\Lambda}_{bb} \end{pmatrix}.$$

同様に,  $\boldsymbol{\Lambda}_{ba}^T = \boldsymbol{\Lambda}_{ab}$  である。

## 2.3.1 条件付きガウス分布

•  $p(x_a|x_b)$ の表現を考えるため, ガウス分布の指数部分に着目する。  
指数部分の二次形式は(2.65),(2.66)より,

$$\begin{aligned} -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}) = & \\ & -\frac{1}{2}(\mathbf{x}_a - \boldsymbol{\mu}_a)^T \boldsymbol{\Lambda}_{aa}(\mathbf{x}_a - \boldsymbol{\mu}_a) - \frac{1}{2}(\mathbf{x}_a - \boldsymbol{\mu}_a)^T \boldsymbol{\Lambda}_{ab}(\mathbf{x}_b - \boldsymbol{\mu}_b) \\ & - \frac{1}{2}(\mathbf{x}_b - \boldsymbol{\mu}_b)^T \boldsymbol{\Lambda}_{ba}(\mathbf{x}_a - \boldsymbol{\mu}_a) - \frac{1}{2}(\mathbf{x}_b - \boldsymbol{\mu}_b)^T \boldsymbol{\Lambda}_{bb}(\mathbf{x}_b - \boldsymbol{\mu}_b) \end{aligned} \quad (2.70)$$

と分解でき,  $x_b$ を固定して考えると,  $x_a$  の二次形式になっている。  
これと, 次の一般の $x$ の二次形式と比較する。

$$-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}) = -\frac{1}{2}\mathbf{x}^T \boldsymbol{\Sigma}^{-1}\mathbf{x} + \mathbf{x}^T \boldsymbol{\Sigma}^{-1}\boldsymbol{\mu} + \text{const.} \quad (2.71)$$

## 2.3.1 条件付きガウス分布

- (2.70) の  $\mathbf{x}_a$  の二次の項をとりだすと,

$$-\frac{1}{2} \mathbf{x}_a^T \Lambda_{aa} \mathbf{x}_a$$

これを (2.71) の  $\mathbf{x}_a$  の二次の項と比較して

$$\Sigma_{a|b} = \Lambda_{aa}^{-1}$$

を得る。次に一次の項を考え、 $\Lambda_{ba}^T = \Lambda_{ab}$  の性質を利用すると,

$$\mathbf{x}_a^T \{ \Lambda_{aa} \mu_a - \Lambda_{ab} (\mathbf{x}_b - \mu_b) \}$$

という一次の項が得られる。これと一般形 (2.71) の一次の項と比較して,

$$\begin{aligned} \mu_{a|b} &= \Sigma_{a|b} \{ \Lambda_{aa} \mu_a - \Lambda_{ab} (\mathbf{x}_b - \mu_b) \} \\ &= \mu_a - \Lambda_{aa}^{-1} \Lambda_{ab} (\mathbf{x}_b - \mu_b) \end{aligned}$$

という形で平均が得られる。

## 2.3.1 条件付きガウス分布

$$\begin{aligned}\mu_{a|b} &= \Sigma_{a|b} \{ \Lambda_{aa} \mu_a - \Lambda_{ab} (\mathbf{x}_b - \mu_b) \} \\ &= \mu_a - \Lambda_{aa}^{-1} \Lambda_{ab} (\mathbf{x}_b - \mu_b)\end{aligned}$$

$$\Sigma_{a|b} = \Lambda_{aa}^{-1}$$

をもとの分割された共分散行列で表現する。関形式

$$\begin{pmatrix} \Sigma_{aa} & \Sigma_{ab} \\ \Sigma_{ba} & \Sigma_{bb} \end{pmatrix}^{-1} = \begin{pmatrix} \Lambda_{aa} & \Lambda_{ab} \\ \Lambda_{ba} & \Lambda_{bb} \end{pmatrix}$$

と、次のシュア補行列を用いて、

$$\begin{pmatrix} \mathbf{A} & \mathbf{B} \\ \mathbf{C} & \mathbf{D} \end{pmatrix}^{-1} = \begin{pmatrix} \mathbf{M} & -\mathbf{M}\mathbf{B}\mathbf{D}^{-1} \\ -\mathbf{D}^{-1}\mathbf{C}\mathbf{M} & \mathbf{D}^{-1} + \mathbf{D}^{-1}\mathbf{C}\mathbf{M}\mathbf{B}\mathbf{D}^{-1} \end{pmatrix}, \quad \mathbf{M} = (\mathbf{A} - \mathbf{B}\mathbf{D}^{-1}\mathbf{C})^{-1}.$$

$$\Lambda_{aa} = (\Sigma_{aa} - \Sigma_{ab}\Sigma_{bb}^{-1}\Sigma_{ba})^{-1}$$

$$\Lambda_{ab} = -(\Sigma_{aa} - \Sigma_{ab}\Sigma_{bb}^{-1}\Sigma_{ba})^{-1}\Sigma_{ab}\Sigma_{bb}^{-1}$$

という関形式を得るので、結局、

$$\mu_{a|b} = \mu_a + \Sigma_{ab}\Sigma_{bb}^{-1}(\mathbf{x}_b - \mu_b)$$

$$\Sigma_{a|b} = \Sigma_{aa} - \Sigma_{ab}\Sigma_{bb}^{-1}\Sigma_{ba}$$

となり、条件付きガウス分布の平均と分散が表現できる。

## 2.3.2 周辺ガウス分布

### • 周辺分布

$$p(\mathbf{x}_a) = \int p(\mathbf{x}_a, \mathbf{x}_b) d\mathbf{x}_b$$

もガウス分布になることを確認する。

まず,  $\mathbf{x}_b$  を積分消去するため, (2.70) から  $\mathbf{x}_b$  を含む項を取り出すと,

$$-\frac{1}{2}\mathbf{x}_b^T \Lambda_{bb} \mathbf{x}_b + \mathbf{x}_b^T \mathbf{m} = -\frac{1}{2}(\mathbf{x}_b - \Lambda_{bb}^{-1} \mathbf{m})^T \Lambda_{bb} (\mathbf{x}_b - \Lambda_{bb}^{-1} \mathbf{m}) + \frac{1}{2} \mathbf{m}^T \Lambda_{bb}^{-1} \mathbf{m} \quad (2.84)$$

ただし,  $\mathbf{m} = \Lambda_{bb} \mu_b - \Lambda_{ba} (\mathbf{x}_a - \mu_a)$

(2.84) の右辺第1項は標準的なガウス分布の二次形式部分なので, この部分を指数にとった積分

$$\int \exp \left\{ -\frac{1}{2} (\mathbf{x}_b - \Lambda_{bb}^{-1} \mathbf{m})^T \Lambda_{bb} (\mathbf{x}_b - \Lambda_{bb}^{-1} \mathbf{m}) \right\} d\mathbf{x}_b.$$

は共分散行列の逆行列にのみ依存する正規化係数の逆数になる。  
よって  $\mathbf{x}_b$  を積分消去することができる。

## 2.3.2 周辺ガウス分布

- mも含め、残る $x_a$ に関する項のみをまとめると、

$$\begin{aligned} & \frac{1}{2} [\Lambda_{bb}\mu_b - \Lambda_{ba}(x_a - \mu_a)]^T \Lambda_{bb}^{-1} [\Lambda_{bb}\mu_b - \Lambda_{ba}(x_a - \mu_a)] \\ & - \frac{1}{2} x_a^T \Lambda_{aa} x_a + x_a^T (\Lambda_{aa}\mu_a + \Lambda_{ab}\mu_b) + \text{const} \\ = & - \frac{1}{2} x_a^T (\Lambda_{aa} - \Lambda_{ab}\Lambda_{bb}^{-1}\Lambda_{ba}) x_a \\ & + x_a^T (\Lambda_{aa} - \Lambda_{ab}\Lambda_{bb}^{-1}\Lambda_{ba}) \mu_a + \text{const} \end{aligned}$$

これを再び(2.71)と比較すると、

$$\Sigma_a = (\Lambda_{aa} - \Lambda_{ab}\Lambda_{bb}^{-1}\Lambda_{ba})^{-1}$$

これより、平均は

$$\Sigma_a (\Lambda_{aa} - \Lambda_{ab}\Lambda_{bb}^{-1}\Lambda_{ba}) \mu_a = \mu_a$$

となり、精度行列とシュア補行列を用いて、

$$(\Lambda_{aa} - \Lambda_{ab}\Lambda_{bb}^{-1}\Lambda_{ba})^{-1} = \Sigma_{aa}$$

となるので、結局、周辺分布の平均と分散は、それぞれの集合の平均と分散であらわされることがわかる。

## 2.3.3 ガウス変数に対するベイズの定理

- あるガウス周辺分布 $p(\mathbf{x})$ と平均が $\mathbf{x}$ の線形関数で、共分散は $\mathbf{x}$ とは独立なガウス条件付き分布 $p(\mathbf{y}|\mathbf{x})$ を考える。  
これは、**線形ガウスモデル**の例である。

周辺分布と条件付き分布を

$$p(\mathbf{x}) = \mathcal{N}(\mathbf{x}|\boldsymbol{\mu}, \boldsymbol{\Lambda}^{-1})$$
$$p(\mathbf{y}|\mathbf{x}) = \mathcal{N}(\mathbf{y}|\mathbf{A}\mathbf{x} + \mathbf{b}, \mathbf{L}^{-1})$$

とおく。

## 2.3.3 ガウス変数に対するベイズの定理

- まず,  $x$ と $y$ の同時分布の表現を求める。次のような $z$ を定義する。

$$z = \begin{pmatrix} x \\ y \end{pmatrix}$$

同時分布の対数を考えると,

$$\begin{aligned} \ln p(z) &= \ln p(x) + \ln p(y|x) \\ &= -\frac{1}{2}(x - \mu)^T \Lambda (x - \mu) \\ &\quad - \frac{1}{2}(y - Ax - b)^T L (y - Ax - b) + \text{const} \end{aligned}$$

$x, y$ の2次の項を取り出すと,

$$\begin{aligned} &-\frac{1}{2}x^T(\Lambda + A^T L A)x - \frac{1}{2}y^T L y + \frac{1}{2}y^T L A x + \frac{1}{2}x^T A^T L y \\ &= -\frac{1}{2} \begin{pmatrix} x \\ y \end{pmatrix}^T \begin{pmatrix} \Lambda + A^T L A & -A^T L \\ -L A & L \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = -\frac{1}{2} z^T R z. \end{aligned}$$

よって, 共分散行列は

$$\text{cov}[z] = R^{-1} = \begin{pmatrix} \Lambda^{-1} & \Lambda^{-1} A^T \\ A \Lambda^{-1} & L^{-1} + A \Lambda^{-1} A^T \end{pmatrix}$$



## 2.3.3 ガウス変数に対するベイズの定理

- 平均は1次の項

$$\mathbf{x}^T \Lambda \boldsymbol{\mu} - \mathbf{x}^T \mathbf{A}^T \mathbf{L} \mathbf{b} + \mathbf{y}^T \mathbf{L} \mathbf{b} = \begin{pmatrix} \mathbf{x} \\ \mathbf{y} \end{pmatrix}^T \begin{pmatrix} \Lambda \boldsymbol{\mu} - \mathbf{A}^T \mathbf{L} \mathbf{b} \\ \mathbf{L} \mathbf{b} \end{pmatrix}$$

と  $\mathbf{x}^T \Sigma^{-1} \boldsymbol{\mu}$  を比較して,

$$\mathbb{E}[\mathbf{z}] = \mathbf{R}^{-1} \begin{pmatrix} \Lambda \boldsymbol{\mu} - \mathbf{A}^T \mathbf{L} \mathbf{b} \\ \mathbf{L} \mathbf{b} \end{pmatrix} = \begin{pmatrix} \boldsymbol{\mu} \\ \mathbf{A} \boldsymbol{\mu} + \mathbf{b} \end{pmatrix}$$

を得る。また, これと,

$$\begin{pmatrix} \Lambda^{-1} & \Lambda^{-1} \mathbf{A}^T \\ \mathbf{A} \Lambda^{-1} & \mathbf{L}^{-1} + \mathbf{A} \Lambda^{-1} \mathbf{A}^T \end{pmatrix} \quad \text{と} \quad \Sigma = \begin{pmatrix} \Sigma_{aa} & \Sigma_{ab} \\ \Sigma_{ba} & \Sigma_{bb} \end{pmatrix},$$

の比較により,  $\mathbf{y}$  の周辺確率の平均と分散

$$\begin{aligned} \mathbb{E}[\mathbf{y}] &= \mathbf{A} \boldsymbol{\mu} + \mathbf{b} \\ \text{cov}[\mathbf{y}] &= \mathbf{L}^{-1} + \mathbf{A} \Lambda^{-1} \mathbf{A}^T \end{aligned}$$

が得られる。

## 2.4.4 ガウス分布の最尤推定

- ある多変量ガウス分布から、観測値 $\{x_n\}$ が独立に取れたデータ集合 $X=(x_1, \dots, x_N)^T$ がある時、パラメータを最尤推定法で求める。
- 対数尤度関数は、

$$\ln p(X|\mu, \Sigma) = -\frac{ND}{2} \ln(2\pi) - \frac{N}{2} \ln |\Sigma| - \frac{1}{2} \sum_{n=1}^N (x_n - \mu)^T \Sigma^{-1} (x_n - \mu) \quad (2.118)$$

なので、これを最大化する。 $\mu, \Sigma$ で偏微分し、 $=0$ とにおいて、 $\mu, \Sigma$ の最尤推定量を求めると、

$$\mu_{ML} = \frac{1}{N} \sum_{n=1}^N x_n, \quad \Sigma_{ML} = \frac{1}{N} \sum_{n=1}^N (x_n - \mu_{ML})(x_n - \mu_{ML})^T.$$

この真の分布の下での期待値を求めると、

$$\mathbb{E}[\mu_{ML}] = \mu$$

$$\mathbb{E}[\Sigma_{ML}] = \frac{N-1}{N} \Sigma$$

となるが、共分散は不偏推定量ではないので、次のように補正する。

$$\tilde{\Sigma} = \frac{1}{N-1} \sum_{n=1}^N (x_n - \mu_{ML})(x_n - \mu_{ML})^T.$$

# 逐次推定は来週

---