

# 第8章 グラフィカルモデル

*Pattern  
Recognition  
and  
Machine  
Learning*

修士2年  
浦田 淳司


# 目次

😊 8	グラフィカルモデル
😊 8.1	ベイジアンネットワーク
😊 8.1.1	例：多項式曲線フィッティング
😊 8.1.2	生成モデル
😊 8.1.3	離散変数
😊 8.1.4	線形ガウスモデル
😊 8.2	条件付き独立性
😊 8.2.1	3つのグラフの例
😊 8.2.2	有向分離（D分離）

😊 8.3	マルコフ確率場
😊 8.3.1	条件付き独立性
😊 8.3.2	分解特性
😊 8.3.3	例：画像のノイズ除去
😊 8.3.4	有向グラフとの関係
😊 8.4	グラフィカルモデルにおける推論
😊 8.4.1	連鎖における推論
😊 8.4.2	木
😊 8.4.3	因子グラフ
😊 8.4.4	積和アルゴリズム
😊 8.4.5	max-sumアルゴリズム
😊 8.4.6	一般のグラフにおける厳密推論
😊 8.4.7	ループあり確率伝播
😊 8.4.8	グラフ構造の学習

# グラフィカルモデルの特徴

- A) 確率モデルの構造を視覚化する簡単な方法の提供  
→新しいモデルの設計方針  
→条件つき独立性などのモデルの性質に関する知見
- B) 精巧なモデルにおける推論・学習には複雑な計算が必要  
→数学的な表現をグラフ上の操作として表現




リンク: link, edge, arc  
ノード: node, vertex

- リンクが特定の方向性 — 有向グラフィカルモデル (ベイジアンネットワーク)  
→ 確率変数間の因果関係
- リンクが方向性なし — 無向グラフィカルモデル (マルコフ確率場)  
→ 確率変数間の緩い束縛関係

※有向閉回路なし (非循環)

# 8.1 ベイジアンネットワーク



$$p(a, b, c) = p(c | a, b) p(b | a) p(a) \cdots (8.2)$$

(aはbの親ノード $\Leftrightarrow$ bはaの子ノード)


K変数の同時分布 $p(x_1, \dots, x_K)$  は, 確率の乗法定理より

$$p(x_1, \dots, x_K) = p(x_K | x_1, \dots, x_{K-1}) \cdots p(x_2 | x_1) p(x_1) \cdots (8.3)$$

自分より小さい番号を振られた全てのノードからのリンクを持つ

.. 全結合

# 8.1 ベイジアンネットワーク



7変数全ての同時分布は

$$p(x_1)p(x_2)p(x_3)p(x_4 | x_1, x_2, x_3)p(x_5 | x_1, x_3)p(x_6 | x_4)p(x_7 | x_4, x_5) \cdots (8.4)$$

同時分布の一般系

$$p(\mathbf{x}) = \prod_{k=1}^K p(x_k | pa_k) \cdots (8.5) \quad pa_k: x_k \text{の親ノードの集合}$$

同時分布を, 各ノードと対応する変数集合の形に分解


# 8.1.1 例) 多項式フィッティング

## ●有向グラフの利用方法

確率変数

- ・多項式係数ベクトル  $\mathbf{w}$
- ・観測データ  $\mathbf{t}$

$$p(\mathbf{t}, \mathbf{w}) = p(\mathbf{w}) \prod_{n=1}^N p(t_n | \mathbf{w}) \cdots (8.6)$$




モデルのパラメータ


- ・入力データ  $\mathbf{x}$
- ・ノイズの分散  $\sigma^2$
- ・ $\mathbf{w}$ 上のガウス事前分布の精度を表す超パラメータ  $\alpha$

明示的に扱うと

$$p(\mathbf{t}, \mathbf{w} | \mathbf{x}, \alpha, \sigma^2) = p(\mathbf{w} | \alpha) \prod_{n=1}^N p(t_n | \mathbf{w}, x_n, \sigma^2)$$




# 8.1.1 例) 多項式フィッティング



$w$ は観測されていない → 潜在変数  
 $\{t_n\}$ の値を観測すると係数 $w$ の事後分布を求められる  
 (1.2.5より)

$$p(\mathbf{w} | \mathbf{t}) \propto p(\mathbf{w}) \prod_{n=1}^N p(t_n | \mathbf{w}) \cdots (8.7)$$

多項式フィッティングの最終目的: 新しい入力値 $x$ に対する $t$ の確率分布を求める



$$p(\hat{t}, \mathbf{t}, \mathbf{w} | \hat{x}, \mathbf{x}, \alpha, \sigma^2) = \left[ \prod_{n=1}^N p(t_n | x_n, \mathbf{w}, \sigma^2) \right] p(\mathbf{w} | \alpha) p(\hat{t} | \hat{x}, \mathbf{w}, \sigma^2) \cdots (8.8)$$

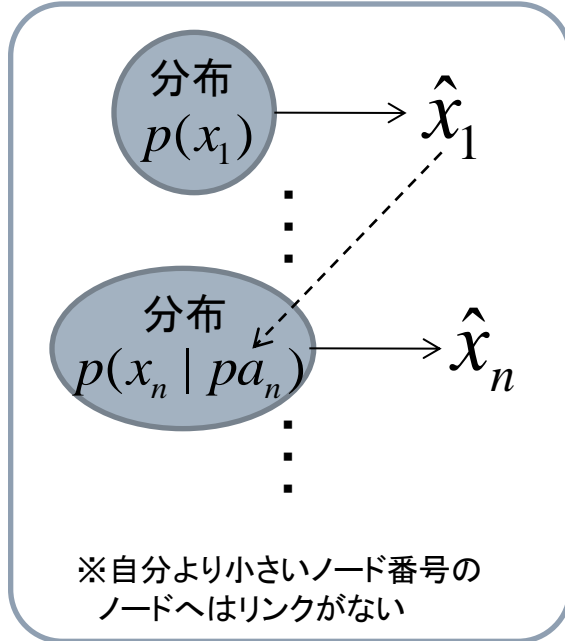
$w$ を積分消去すると

$$p(\hat{t} | \hat{x}, \mathbf{x}, \mathbf{t}, \alpha, \sigma^2) \propto \int p(\hat{t}, \mathbf{t}, \mathbf{w} | \hat{x}, \mathbf{x}, \alpha, \sigma^2) dw$$

$\hat{t}$ の予測分布

## 8.1.2 生成モデル

サンプリング法(11章)→伝承サンプリング



観測データが生成される**因果過程**を表現  
→生成モデル

※多項式回帰モデル: 入力変数 $x$ は確率分布ではない  
→生成モデルではない

生成モデル→

観測データと同じ確率分布に従う「架空」データを発生できる



## 8.1.3 離散変数

グラフィカルモデル: 構成要素の接続を表現

→ 有向グラフの親子対が共役関係になる分布であると, とくによい性質

→ 特に, 離散変数, ガウス変数の場合は有効非循環グラフへ拡張可能

K個の状態をとりうる離散変数 $x$ の確率分布 
$$p(x | \boldsymbol{\mu}) = \prod_{k=1}^K \mu_k^{x_k} \cdots (8.9)$$

パラメータ  $\boldsymbol{\mu} = (\mu_1, \dots, \mu_K)^T$  により支配  
規格化制約  $\sum_k \mu_k = 1$  により, パラメータは  $K-1$  個指定すればよい

2つのK状態離散変数 $x_1$ 及び $x_2$ がある場合

$$p(x_1, x_2 | \boldsymbol{\mu}) = \prod_{k=1}^K \prod_{l=1}^K \mu_{kl}^{x_{1k} x_{2l}}$$

規格化制約  $\sum_k \sum_l \mu_{kl} = 1$   $K^2-1$  個のパラメータ

変数M個の時:  $K^M-1$  個のパラメータ → 指数的に増大

# 8.1.3 離散変数


$$p(x_1, x_2 | \mu) = \prod_{k=1}^K \prod_{l=1}^K \mu_{kl}^{x_{1k} x_{2k}}$$

a) 乗法の定理 同時分布  $p(x_1, x_2) = p(x_2 | x_1) p(x_1)$

全パラメータ数は  $K^2 - 1$


b) 変数  $x_1$  と  $x_2$  が独立 → 各変数は別々の多項分布

全パラメータ数は  $2(K-1)$  ∴ 線形に増加



→ リンク除去によりパラメータ数減

リンクの数によって、パラメータ数の増え方が変わる



周辺分布	$p(x_i)$	$K-1$ 個
条件つき分布	$p(x_i   x_{i-1})$	$K(K-1)$ 個 $\times (M-1)$
線形増加		

パラメータにディリクレ事前分布を導入

## 8.1.4 線形ガウスモデル

要素変数上の線形ガウスモデルに対応する有向グラフにより,  
多変量ガウス分布を表現する方法

ノード $i$ ーガウス分布に従う連続値確率変数 $x_i$

$$p(x_i | pa_i) = \mathcal{N}\left(x_i \mid \sum_{j \in pa_i} \omega_{ij} x_j + b_i, v_i\right) \cdots (8.11)$$

$p(\mathbf{x}) = \prod_{k=1}^K p(x_k | pa_k) \cdots (8.5)$  より, 同時分布の対数は,

$$\begin{aligned} \ln p(x) &= \sum_{i=1}^D \ln p(x_i | pa_i) \\ &= -\sum_{i=1}^D \frac{1}{2v_i} \left( x_i - \sum_{j \in pa_i} \omega_{ij} x_j - b_i \right)^2 + const \cdots (8.13) \end{aligned} \quad \left[ \begin{array}{l} \mathcal{N}\left(x_i \mid \sum_{j \in pa_i} \omega_{ij} x_j + b_i, v_i\right) \\ = \frac{1}{(2\pi v_i)^{1/2}} \exp\left\{-\frac{1}{2v_i} \left(x_i - \left(\sum_{j \in pa_i} \omega_{ij} x_j + b_i\right)\right)^2\right\} \end{array} \right]$$

これは $\mathbf{x}$ の成分に関する二次関数  
→同時分布 $p(\mathbf{x})$ は多変量ガウス分布

## 8.1.4 線形ガウスモデル

### ●同時分布の平均

$$(8.11)に従うので \quad x_i = \sum_{j \in pa_i} \omega_{ij} x_j + b_i + \sqrt{v_i} \varepsilon_i \quad \cdots (8.14)$$

※  $\varepsilon$  は平均0, 分散1のガウス確率変数

期待値は

$$E[x_i] = \sum_{j \in pa_i} \omega_{ij} E[x_j] + b_i \quad \cdots (8.15)$$

有向非循環グラフなので,  $E(x)$ の全成分を再帰的に求められる

### ●同時分布の共分散行列


$$\begin{aligned} \text{cov}[x_i, x_j] &= E[(x_i - E[x_i])(x_j - E[x_j])] = E \left[ (x_i - E[x_i]) \left\{ \sum_{k \in pa_j} \omega_{jk} (x_k - E[x_k]) + \sqrt{v_j} \varepsilon_j \right\} \right] \\ &= E \left[ \sum_{k \in pa_j} \omega_{jk} (x_i - E[x_i])(x_k - E[x_k]) + \left\{ \sum_{k \in pa_i} \omega_{ik} (x_k - E[x_k]) + \sqrt{v_i} \varepsilon_i \right\} \cdot \sqrt{v_j} \varepsilon_j \right] = \sum_{k \in pa_j} \omega_{jk} \text{cov}[x_i, x_k] + I_{ij} v_j \quad \cdots (8.16) \end{aligned}$$

共分散についても, 再帰的に値を求める

## 8.1.4 線形ガウスモデル

(2章より)

ガウス変数 $x$ の平均 $\mu$ に関する共役事前分布がガウス分布である場合,  
 $x$ および $\mu$ 上の同時分布はガウス分布になる



$\mu$ 上の分布の平均は事前分布を制御するパラメータなので,  
超パラメータとみなされる.



超パラメータの値自体が未知なので,  
超パラメータにも事前分布を導入する.  
(超事前分布)



これもガウス分布とすれば, ベイズ的取り扱いが可能  
→階層ベイズモデルの一例

## 8.2 条件付き独立性

### 条件付き独立性

3変数 $a, b, c$ を考えたとき,  $a$ の条件付き分布が $b$ の値に依存しない. つまり

$$p(a | b, c) = p(a | c) \cdots (8.20)$$

このとき,  $c$ が与えられた下で,  $a$ は $b$ に対して条件付き独立であるという

$c$ が与えられたとき( $c$ のとりうる全ての可能な値に対して),

(8.20)が成り立つとき, 次のように示す.

$$a \perp\!\!\!\perp b \mid c$$




条件付き独立: モデル構造の簡略化には重要

→ グラフィカルモデルにより

同時分布の条件付き独立を直接グラフから読み取れる

→ 有向分離

## 8.2.1 3つのグラフの例①




$$p(a, b, c) = p(a | c) p(b | c) p(c)$$

a, bが独立かを調べる(cの周辺化)

$$p(a, b) = \sum_c p(a | c) p(b | c) p(c) \cdots (8.24)$$

$p(a)p(b)$ の形に分解できない  $\rightarrow a \not\perp b | \emptyset$



変数cで条件づけ


$$p(a, b | c) = \frac{p(a, b, c)}{p(c)} = p(a | c) p(b | c)$$

$$\rightarrow a \perp b | c$$

cは経路に対して、tail-to-tailとなっている

二つのtailでつながれており、経路が存在し、非独立  
cにより、a, b経路が遮断され(条件付き)独立となる


## 8.2.1 3つのグラフの例②



$$p(a, b, c) = p(a)p(c|a)p(b|c) \cdots (8.26)$$

cについて周辺化

$$p(a, b) = p(a) \sum_c p(c|a)p(b|c) = p(a)p(b|a)$$
$$\rightarrow a \not\perp b \mid \emptyset$$



変数cで条件づけ

ベイズの定理と(8.26)式より

$$p(a, b | c) = \frac{p(a, b, c)}{p(c)} = \frac{p(a)p(c|a)p(b|c)}{p(c)} = p(a|c)p(b|c)$$
$$\rightarrow a \perp b \mid c$$


cは経路に対して、head-to-tailとなっている

cが観測されないときは、経路よりa,bは従属関係となる

cが観測されることでa→b経路を遮断し、条件付き独立



## 8.2.1 3つのグラフの例③




$$p(a,b,c) = p(a)p(b)p(c|a,b) \cdots (8.28)$$

cについて周辺化

$$p(a,b) = p(a)p(b) \rightarrow a \perp\!\!\!\perp b \mid \emptyset$$

どの変数も観測されていないとき, a,bは独立である



変数cで条件づけ

$$p(a,b|c) = \frac{p(a,b,c)}{p(c)} = \frac{p(a)p(b)p(c|a,b)}{p(c)} \rightarrow a \not\perp\!\!\!\perp b \mid c$$

cは経路に対して, head-to-headとなっている


cが観測されない時, a,bの関係は遮断されている

cが観測されると, 遮断が解かれ, 依存関係に

(cの子孫が観測されても遮断は解かれる).


## 8.2.2 有向分離 (D分離)

$a \perp\!\!\!\perp b \mid c$  について考える.



- ・ aからbへの経路はfによって遮断されない  
→ f: tail-to-tailで, 観測されない
- ・ aからbへの経路はeによって遮断されない  
→ e: head-to-headで, 子孫cが条件づけ(観測)


$a \perp\!\!\!\perp b \mid c$  は導けない



- ・ aからbへの経路はfによって遮断される  
→ f: tail-to-tailで, 観測されている
- ・ aからbへの経路はeによって遮断される  
→ e: head-to-headで, 子孫も条件づけなし

$a \perp\!\!\!\perp b \mid c$  といえる

## 8.2.2 有向分離 (D分離)




パラメータノード: 観測済みノード

親ノードなし

すべての経路はtail-to-tail

→他ノードの有向分離性に影響なし



1変量ガウス分布の平均の事後分布について

$D = \{x_1, \dots, x_N\}$  が観測されたもとでの  $\mu$  の推論

$\mu$  を条件付け変数とみなし, 観測変数の同時分布を考える.

$$p(D | \mu) = \prod_{n=1}^N p(x_n | \mu) \cdots (8.34) \quad \text{※観測値Dは互いに独立}$$

$\mu$  を消去した場合は, 観測値は一般に独立ではない.

$$p(D) = \int_{-\infty}^{\infty} p(D | \mu) p(\mu) d\mu \neq \prod_{n=1}^N p(x_n) \cdots (8.35) \quad \text{※} \mu \text{ は観測されず, 潜在変数}$$

## 8.2.2 有向分離 (D分離)


### ベイズ多項式回帰モデルについて

多項式変数 $w$ が条件付けられれば,  $w$ はtail-to-tailなので


$$\hat{t} \perp\!\!\!\perp t_n \mid w$$

$\hat{t}$ の予測分布は訓練データ $t_n$ に対して独立

→ 訓練データより $w$ の事後分布を決定すれば,  $t_n$ はいらない



### マルコフブランケット(マルコフ境界)



$$p(x_i \mid x_{\{j \neq i\}}) = \frac{p(x_1, \dots, x_D)}{\int p(x_1, \dots, x_D) dx_i} = \frac{\prod_k p(x_k \mid pa_k)}{\int \prod_k p(x_k \mid pa_k) dx_i}$$

$x_i$ に関係ない項は分母分子でキャンセル

残る項は

- ・  $x_i$ の条件付き分布  $p(x_i \mid pa_i)$
- ・  $x_i$ を条件付け変数集合に含む  
任意の  $x_k$  の条件付き分布  $p(x_k \mid pa_k)$

一親  
一子・共同親

## 8.3 マルコフ確率場

### 有向グラフィカルモデル(ベイジアンネットワーク)

- 確率変数間の因果関係, リンクが特定の方向性
- 同時分布を局所的な条件つき分布の積に因数分解
- 因数分解される分布の条件つき独立性の集合


### 無向グラフィカルモデル(マルコフ確率場)

- 確率変数間の緩い束縛関係, リンクは方向性なし
- ノード集合とリンク集合

## 8.3.1 条件付き独立性

有向グラフ: 有向分離, head-to-headとtail-to-tailの混在

無向グラフ: 親ノードと子ノードの非対称性なし



$A \perp\!\!\!\perp B \mid C$  を判断するには...

集合Aと集合Bを結ぶ全ての経路

→ 集合Cのノードを少なくとも一つ含む

→ 全ての経路が遮断され, 条件付き独立  
(集合Cを除いた時, A-B経路の存在有無)

無向グラフのマルコフブランケット


→ 隣接ノード集合

## 8.3.2 分解特性

直接接続されない2つのノード $x_i, x_j$ は条件付き独立

$$p(x_i, x_j \mid \mathbf{x}_{\setminus\{ij\}}) = p(x_i \mid \mathbf{x}_{\setminus\{ij\}})p(x_j \mid \mathbf{x}_{\setminus\{ij\}}) \cdots (8.38)$$

$x_i, x_j$ が因子に含まれないように, 因数分解される



クリーク:

全てのノードの組にリンクが存在するグラフの部分集合

$\{x_1, x_2\}, \{x_2, x_3\}, \{x_3, x_4\}, \{x_4, x_2\}, \{x_1, x_3\},$

$\{x_1, x_2, x_3\}, \{x_2, x_3, x_4\}$  ← 極大クリーク

同時分布を因数分解したときの各因子を,  
クリークが含む変数の集合の関数すれば良い

## 8.3.2 分解特性

クリーク $C$ , クリーク内の変数の集合 $x_c$ とする.

同時分布は, 極大クリーク上のポテンシャル関数 $\psi_c(x_c)$ の積の形でかける.

$$p(x) = \frac{1}{Z} \prod_C \psi_c(\mathbf{x}_C) \cdots (8.39)$$

$Z$ は規格化定数(分配関数)であり,

$$Z = \sum_{\mathbf{x}} \prod_C \psi_c(\mathbf{x}_C) \cdots (8.40)$$

ポテンシャル関数は,

周辺分布や条件付き分布のように確率的解釈が可能なものに**限定されない**

※規格化定数が必要. 積と和の計算により, モデルサイズに応じて計算量増

---

### 定式化

ポテンシャル関数 $\psi_c(x_c)$ が狭義に正(因数分解と条件付き独立の関係から)  
指数関数で表現

$$\psi_c(\mathbf{x}_C) = \exp \{-E(\mathbf{x}_C)\} \cdots (8.41)$$

( $E(x_c)$ )はエネルギー関数, この指数表現はボルツマン分布)


ポテンシャル関数は確率的解釈はないので, ポテンシャル関数は自由に選べる  
→選び方は・・・局所的な変数がどのような形状を持てばいいのか



# 8.3.3 例：画像のノイズ除去


ノイズなし

値 $y_i$ (10%反転)



ICM法  
(96%一致)

グラフカットアルゴリズム  
(99%一致)



観測画像2値ピクセル値 $y_i \in \{-1, 1\}$ の二次元配列  
(ノイズのない2値画像 $x_i \in \{-1, 1\}$ からランダムに反転)

ノイズレベルが低いために  
 $x_i$ と $y_i$ との間に強い相関が残っているはず。

$$-\eta x_i y_i$$

隣接ピクセル $x_i$ と $x_j$ との間に強い相関があるはず。

$$-\beta x_i x_j$$

同符号の時, 低いエネルギー(高い確率)  
異符号の時, 高いエネルギー(低い確率)

$$E(\mathbf{x}, \mathbf{y}) = h \sum_i x_i - \beta \sum_{\{i, j\}} x_i x_j - \eta \sum_i x_i y_i \quad \cdots (8.42)$$

$$p(\mathbf{x}, \mathbf{y}) = \frac{1}{Z} \exp \{-E(\mathbf{x}, \mathbf{y})\} \quad \cdots (8.43)$$

$h$   $x_i$ は特定の符号を持ちやすくするためのバイアス効果


and Machine Learning

## 8.3.3 例：画像のノイズ除去

画像復元のために高い確率を持つ画像 $x$ を求めたい(イジングモデル)

### ●ICM法(反復条件付きモード)

1. 変数 $\{x_i\}$ を初期化( $x_i=y_i$ など)
  2. あるノード $x_j$ を選ぶ
  3.  $x_j=+1$ と $x_j=-1$ における全エネルギーを計算
  4. エネルギーが小さくなる方に $x_j$ を設定
  5. 2に戻り, 違う場所で計算
  6. ある規準になるまで繰り返し
- 全ての場所を少なくとも1回は通るシーケンスで, 値が更新されず  
→極大点の発見



# 8.3.4 有向グラフとの関係

有向グラフ

$$p(\mathbf{x}) = p(x_1)p(x_2 | x_1)p(x_3 | x_2) \cdots p(x_N | x_{N-1}) \cdots (8.44)$$



無向グラフ

$$p(\mathbf{x}) = \frac{1}{Z} \psi_{1,2}(x_1, x_2) \psi_{2,3}(x_2, x_3) \cdots \psi_{N-1,N}(x_{N-1}, x_N) \cdots (8.45)$$




→対応付け

$$\begin{cases} \psi_{1,2}(x_1, x_2) = p(x_1)p(x_2 | x_1) \\ \psi_{2,3}(x_2, x_3) = p(x_3 | x_2) \\ \vdots \\ \psi_{N-1,N}(x_{N-1}, x_N) = p(x_N | x_{N-1}) \end{cases}$$

無向グラフ                      有向グラフ  
クリークポテンシャル関数 ⇔ 条件付き分布

変換の正確さ


[有向]条件付き分布の変数集合全て → [無向]1つのクリーク集合に含まれる




$$p(\mathbf{x}) = p(x_1)p(x_2)p(x_3)p(x_4 | x_1, x_2, x_3)$$

全ての変数が1つのクリーク  
に属さなければならない


→ **モラルグラフ**  
親同士の間  
無向リンクを付加




## 8.4 グラフィカルモデルにおける推論



(a)



(b)



(c)

変数 $y$ の値が観測される(図(b))  $\rightarrow p(y|x)$

潜在変数 $x$ の周辺分布 $p(x)$ は事前分布

確率の加法定理, 乗法定理より

$$p(y) = \sum_{x'} p(y | x') p(x') \cdots (8.47)$$

ベイズの定理より

$$p(x | y) = \frac{p(y | x) p(x)}{p(y)} \cdots (8.48)$$

$x$ の事後分布 $p(x|y)$ が推論された.

# 8.4.1 連鎖における推論



グラフの同時分布は次のようになる

$$p(\mathbf{x}) = \frac{1}{Z} \psi_{1,2}(x_1, x_2) \psi_{2,3}(x_2, x_3) \cdots \psi_{N-1,N}(x_{N-1}, x_N) \cdots (8.49)$$

ノード  $x_n$  の周辺分布は

$$p(x_n) = \sum_{x_1} \cdots \sum_{x_{n-1}} \sum_{x_{n+1}} \cdots \sum_{x_N} p(\mathbf{x}) \cdots (8.50)$$

K状態変数ノードがN個分の計算  $\rightarrow x$  のとりうる状態は  $K^N$  個

$\rightarrow$  周辺分布を求めるには指数オーダーの計算量

## グラフィカルモデルの効率利用

(8.49)を(8.50)に代入  $\sum_{x_N}$  に関係するのは  $\psi_{N-1,N}(x_{N-1}, x_N)$  のみ

$x_N$  については  $\sum_{x_N} \psi_{N-1,N}(x_{N-1}, x_N)$  を計算.  $x_{N-1}$  に関係するのは...


ノード  $x_n$  の周辺分布は

$$p(x_n) = \frac{1}{Z} \underbrace{\left[ \sum_{x_{n-1}} \psi_{n-1,n}(x_{n-1}, x_n) \cdots \left[ \sum_{x_2} \psi_{2,3}(x_2, x_3) \left[ \sum_{x_1} \psi_{1,2}(x_1, x_2) \right] \right] \right]}_{\mu_\alpha(x_n)} \cdots \underbrace{\left[ \sum_{x_{n+1}} \psi_{n,n+1}(x_n, x_{n+1}) \cdots \left[ \sum_{x_N} \psi_{N-1,N}(x_{N-1}, x_N) \right] \right]}_{\mu_\beta(x_n)} \quad (8.52)$$

# 8.4.1 連鎖における推論

## 局所的なメッセージの伝搬

(8.52)より  $p(x_n) = \frac{1}{Z} \mu_\alpha(x_n) \mu_\beta(x_n) \cdots$  (8.54)




$\mu_\alpha$ : ノード番号大へ前向きに伝わるメッセージ  
 $\mu_\beta$ : ノード番号小へ後向きに伝わるメッセージ

メッセージ  $\mu_\alpha$  は  $\mu_\alpha(x_n) = \sum_{x_{n-1}} \psi_{n-1,n}(x_{n-1}, x_n) \left[ \sum_{x_{n-2}} \cdots \right] = \sum_{x_{n-1}} \psi_{n-1,n}(x_{n-1}, x_n) \mu_\alpha(x_{n-1}) \cdots$  (8.55)

なので,  $\mu_\alpha(x_2) = \sum_{x_1} \psi_{1,2}(x_1, x_2) \cdots$  (8.56) から再帰的に所望のノードに到達するまで繰り返す  
 後向きも同様. マルコフ連鎖と呼ばれる.

## アルゴリズム的な話



伝播中の全ての(中間的な)メッセージを保存

途中にいくつかのノードが観測されている場合は, 観測値固定

# まとめ


- 有向グラフィカルモデルと無向グラフィカルモデル
- 条件付き確率分布の関係性を明示的に扱う
- グラフの関係性に従い，事前分布・観測変数から他の変数を求めることができる
- 有向グラフィカルモデルでは，有向分離が必要
- 因子グラフを用いての，推論．．

## 8.4.2 木

連鎖 $\Leftrightarrow$ メッセージパッシング  $\leftarrow$  厳密推論


木構造グラフ $\Leftrightarrow$ 積和アルゴリズム  $\leftarrow$  一般化, 厳密推論

無向木



ループを持たない

有向木




ループを持たない

親なしノード1つ  
他ノードは親1つ

無向変換時 モラル化必要なし

有向多重木



ループを持たない

親はいくつでもいい

モラル化必要あり



## 8.4.3 因子グラフ

### ●有向グラフ・無向グラフ

多くの変数に依存する大域的な関数が，局所的な変数の部分集合のみに依存する


### ●因子グラフ

変数を表現するノードに因子(関数)そのものに対応するノードを付け加える

ある変数上の同時分布を因子の積の形で表す

$$p(\mathbf{x}) = \prod f_s(\mathbf{x}_s) \cdots (8.59)$$












$$\left[ \begin{array}{l} \text{有向グラフ} \quad p(\mathbf{x}) = \prod_{k=1}^K p(x_k | pa_k) \cdots (8.5) \quad (8.59) \text{の特別な場合} \end{array} \right]$$



$$p(\mathbf{x}) = f_a(x_1, x_2) f_b(x_1, x_2) f_c(x_2, x_3) f_d(x_3)$$

まとめていない

# 8.4.3 因子グラフ



局所的な  
ループの回避

木構造を  
因子グラフでは保持

同じグラフでの違った因子グラフ表現  
→より正確に因数分解を表現

## 8.4.4 積和アルゴリズム

ノード(ノード部分集合)上の局所的な周辺分布の計算アルゴリズム

木構造の因子グラフに適応(どのグラフからの変換可能)


(i) 周辺分布を求めるための  
効率の良い厳密推論アルゴリズムを得る

(ii) 複数の周辺分布を計算した場合に,  
計算の重複をなくして効率化する

# 8.4.4 積和アルゴリズム

ある特定の変数 $x$ 上の周辺分布 $p(x)$ を求める問題を考える(変数は離散的)

周辺分布  $p(x) = \sum_{\mathbf{x} \setminus x} p(\mathbf{x}) \cdots (8.61)$   $x$ 以外の変数の同時分布の和



グラフは木構造なので、  
同時分布を  
因子の変数ノード $x$ に隣接する各因子ノードごとに  
グループ分けできる。

$p(\mathbf{x}) = \prod_{s \in ne(x)} F_s(x, X_s) \cdots (8.62)$  部分木内の同時分布の積が  
全体の同時分布

$ne(x)$ :  $x$ に隣接する因子のノード集合  
 $X_s$ :  $f_s$ を通して変数ノード $x$ に接続される部分木の変数集合  
 $F_s(x, X_s)$ :  $f_s$ に関連するグループすべての因子の積

$$p(x) = \prod_{s \in ne(x)} \left[ \sum_{X_s} F_s(x, X_s) \right] = \prod_{s \in ne(x)} \mu_{f_s \rightarrow x}(x) \cdots (8.63)$$

## 8.4.4 積和アルゴリズム

---