

第14章 モデルの結合

*Pattern
Recognition
and
Machine
Learning*

修士2年
山川佳洋

14章の目次

- モデルの結合
 - ベイズモデル平均化
 - コミッティ
 - ブースティング
 - 指数誤差の最小化
 - ブースティングのための誤差関数
-
- 木構造モデル
 - 条件付き混合モデル
 - 線形回帰モデルの混合
 - ロジスティックモデルの混合
 - 混合エキスパートモデル

概要

■ コミッティ

L個の異なるモデルを訓練した後に、各モデルで得られた予測の平均値を予測値として用いる

→代表的なものに**ブースティング**

■ 決定木

予測に用いる1つのモデルを入力変数の関数として選択するもの

→応用したものに**混合エキスパートモデル**

コミッティ

- **L個の異なるモデル**を訓練した後に、各モデルで得られた**予測の平均値**を予測値として用いる
- 各モデル間には変化が必要
→ **バギング**の利用

M 個の**ブートストラップデータ**集合を生成し、それらデータ集合を用いて個々に独立な M 個の予測モデル $y_m(\mathbf{x})$ のコピーを訓練する.

$$y_{COM}(\mathbf{x}) = \frac{1}{M} \sum_{m=1}^M y_m(\mathbf{x}) \quad (14.7)$$

ブースティング

- コミッティとの違い
→ データを**逐次的**に訓練
- 複数の「**ベース**」分類器を結合する
→ いずれのベース分類器より**高性能**のコミッティ
→ ベース分類器は**弱学習器**と呼ばれる
- 代表的なものに**AdaBoost** (Freund and Schapire, 1996)
- もとは分類問題→回帰問題にも拡張
- 各ベース分類器の訓練→**重み付けられた**データ集合
- 重み係数は**以前の学習**の分類器の性能による

AdaBoost アルゴリズム

1. $n=1, \dots, N$ のデータの重み係数 $\{\omega_n\}$ を $\omega_n^{(1)} = 1/N$ に初期化する

2. $m=1, \dots, M$ について以下を繰り返す

(a) 分類器 $y_m(\mathbf{x})$ を次の重み付けされた誤差関数を最小化するように訓練データにフィットさせる

$$J_m = \sum_{n=1}^N \omega_n^{(m)} I(y_m(\mathbf{x}_n) \neq t_n) \quad (14.15)$$

(b) 次の値(誤差率の尺度)を計算する

$$\varepsilon = \frac{\sum_{n=1}^N \omega_n^{(m)} I(y_m(\mathbf{x}_n) \neq t_n)}{\sum_{n=1}^N \omega_n^{(m)}} \quad (14.16)$$

これを用いて次の量(重み係数)を求める

$$\alpha_m = \ln \left\{ \frac{1 - \varepsilon_m}{\varepsilon_m} \right\} \quad (14.17)$$


(c) データ点の重み係数を以下の式で更新する

$$\omega_n^{(m+1)} = \omega_n^{(m)} \exp \{ \alpha_m I(y_m(\mathbf{x}_n) \neq t_n) \} \quad (14.18)$$

3. 以下の式で、最終モデルの予測をする

$$Y_M(\mathbf{x}) = \text{sign} \left(\sum_{m=1}^M \alpha_m y_m(\mathbf{x}) \right) \quad (14.19)$$

AdaBoost アルゴリズム



$$Y_M(\mathbf{x}) = \text{sign} \left(\sum_m^M \alpha_m y_m(\mathbf{x}) \right)$$

決定木


- **木構造**に沿った一連の二値選択として記述
- 個々には非常に簡単なモデルを用いる
- 分類問題，回帰問題，**いずれ**にも適用

決定木 例 1 (PRMLより)


決定木

木構造の予測モデル

入力空間を多次元の矩形領域に区分する



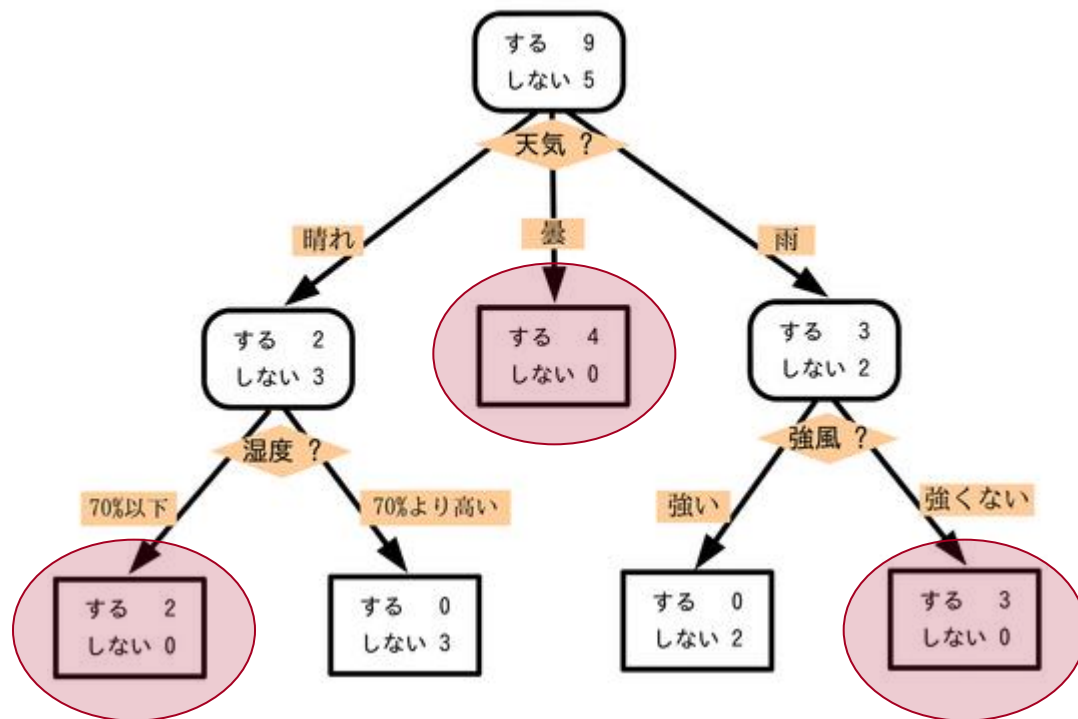
二次元入力空間



決定木 例 2 (wikipediaより)

ゴルフ場の経営者が従業員の勤務体制を最適化する


従属変数: ゴルフをするか



独立変数				従属変数
天気	気温(度)	湿度(%)	風が強い	ゴルフをするか
晴れ	22	95	強くない	しない
晴れ	21	70	強くない	する
晴れ	24	70	強い	する
晴れ	29	85	強くない	しない
晴れ	27	90	強い	しない
曇	27	75	強くない	する
曇	28	78	強くない	する
曇	22	90	強い	する
曇	18	65	強い	する
雨	22	80	強い	しない
雨	21	96	強くない	する
雨	20	80	強くない	する
雨	18	70	強い	しない
雨	24	80	強くない	する

独立変数				従属変数
天気	気温(度)	湿度(%)	風が強い	ゴルフをするか
曇	18	65	強い	する
雨	18	70	強い	しない
雨	20	80	強くない	する
晴れ	21	70	強くない	する
雨	21	96	強くない	する
雨	22	80	強い	しない
曇	22	90	強い	する
晴れ	22	95	強くない	しない
晴れ	24	70	強い	する
雨	24	80	強くない	する
晴れ	27	90	強い	しない
曇	27	75	強くない	する
曇	28	78	強くない	する
晴れ	29	85	強くない	しない

決定木 例 2 イメージ図



決定木！

目標変数を予測するためのモデルは各領域に個別に存在

回帰問題では領域ごとに単純に定数値を予測

→家賃の見積もり(駅からの距離, 広さ, 築年数など)

分類問題では各領域に特定のクラスを割り当てる

→医療診断(体温, 血圧など)

訓練集合からの学習

各ノードにおいて分割規準として利用する入力変数を選択肢し

閾値 θ_i を決めることで木構造を決定する

領域ごとに予測する変数の値を決定する


D次元ベクトル $\mathbf{x} = (x_1, \dots, x_D)^T$ から一次元の目標変数 t を予測する

訓練データ

連続ラベル $\{t_1, \dots, t_N\}$ を伴う入力ベクトル $\{x_1, \dots, x_N\}$

回帰モデルの分割方法

入力空間の分割を二乗誤差を最小にするように
与えるならば予測変数の最適値は領域内のデータ点の平均値となる



ノードの追加を終わらせる条件 T : 葉

$$y_\tau = \frac{1}{N_\tau} \sum_{x_n \in R_\tau} t_n \quad (14.29)$$


$$Q_\tau(T) = \sum_{x_n \in R_\tau} \{t_n - y_\tau\}^2 \quad (14.30)$$

$$C(T) = \sum_{\tau=1}^{|T|} Q_\tau(T) + \lambda |T| \quad (14.31)$$

分類問題の分割方法

ジニ係数

$$Q_{\tau}(T) = \sum_{k=1}^K p_{\tau k} (1 - p_{\tau k}) \quad (14.33)$$



最小となるように分割

2クラス分類(赤と青)

① $\frac{3}{4} * \frac{1}{4} + \frac{1}{4} * \frac{3}{4} = \frac{3}{8}$

② $\frac{4}{5} * \frac{1}{5} + \frac{0}{3} * \frac{3}{3} = \frac{4}{25}$

③ $\frac{4}{4} * \frac{0}{4} + \frac{0}{4} * \frac{4}{4} = 0$

③ < ② < ①

決定木！！

- 人における可読性が木モデルの強み
- データ集合の細部に非常に敏感
→ データのわずかな違いから結果が大きく変わることも
- 分割が特徴空間の軸に沿わせているため準最適となる
- 回帰問題で予測が分離境界において不連続
- 入力空間分割がハードな分割
→ 確率的な枠組みの導入でソフトに
→ 混合エキスパートモデル

$$p(t|\mathbf{x}) = \sum_{k=1}^K \pi_k(\mathbf{x}) p(t|\mathbf{x}, k) \quad (14.53) \quad \pi_k(\mathbf{x}) = p(k|\mathbf{x})$$